

Akademia Górniczo – Hutnicza im. Stanisława Staszica w Krakowie

*Wydział Fizyki i Informatyki Stosowanej
Informatyka Stosowana*



Projekt

Metody Inteligencji Obliczeniowej

*prowadzący: dr hab. inż. Piotr Kowalski
dr inż. Szymon Łukasik*

Predykcja indeksu giełdowego S&P 500 z użyciem procedury ANFIS

Opracowanie:

Jakub Salamon
Izabela Snażyk
Dominik Trybuch

Kraków, 24.01.2018

1. Predykcja indeksu giełdowego

Do efektywnego opracowywania strategii inwestycyjnych, mogących przynosić duże zyski w inwestycjach giełdowych, wykorzystywanych jest wiele technik analizujących historyczne wartości cen akcji dla różnorodnych rodzajów indeksów giełdowych. Używane dzisiaj techniki pozwalają w lepszy lub gorszy sposób krótkoterminowo prognozować wartości tych indeksów. Istnieje cały szereg metod predykcyjnych - poczynając od podstawowych analiz technicznych wykresów wartości indeksu wykonywanych przez inwestorów, po ogromne systemy informatyczne wykorzystujące jednokierunkowe oraz rekurencyjne sieci neuronowe wspomagane algorytmami genetycznymi.


Taka analiza techniczna indeksu giełdowego podlega intuicyjnym zasadom, których w oczywisty sposób muszą przestrzegać efektywnie działające systemy predykcji giełdowych. Wprawne odnajdywanie zaistniałych na rynku trendów oraz sytuacji mogących te trendy odwrócić, powtarzalność według określonych schematów, dobór danych uczących oraz uwzględnianie w analizach jak największej ilości różnorodnych danych mogących mieć wpływ na wartości indeksu - wszystko to po to, aby prognozy były jak najbardziej zbliżone do realnego zachowania giełdy.

W opracowanym przez nas projekcie przyjrzelśmy się dokładnie jednej z metod predykcji indeksu giełdowego – procedurze ANFIS. Następnie wspomagając się zaimplementowanym przez nas algorytmem decyzyjnym – systemem wnioskowania rozmytego, staraliśmy się określić z jaką efektywnością nasz system predykcyjny może być wykorzystany w strategiach inwestycyjnych.

Wykorzystywane przez nas analizy techniczne pozwalają na krótkoterminowe prognozowanie – predykcji konkretnej wartości indeksu giełdowego dla jednego dnia wprzód, bazując na kilku dniach poprzedzających. Taki system może mieć zastosowanie tylko dla tych inwestorów którym zależy na szybkiej kalkulacji zysków i strat nie narażając się na większe ryzyko. System ten nie obejmuje tzw. analizy fundamentalnej spółek akcyjnych, natomiast opiera się tylko i wyłącznie na analizie historycznych notowań.

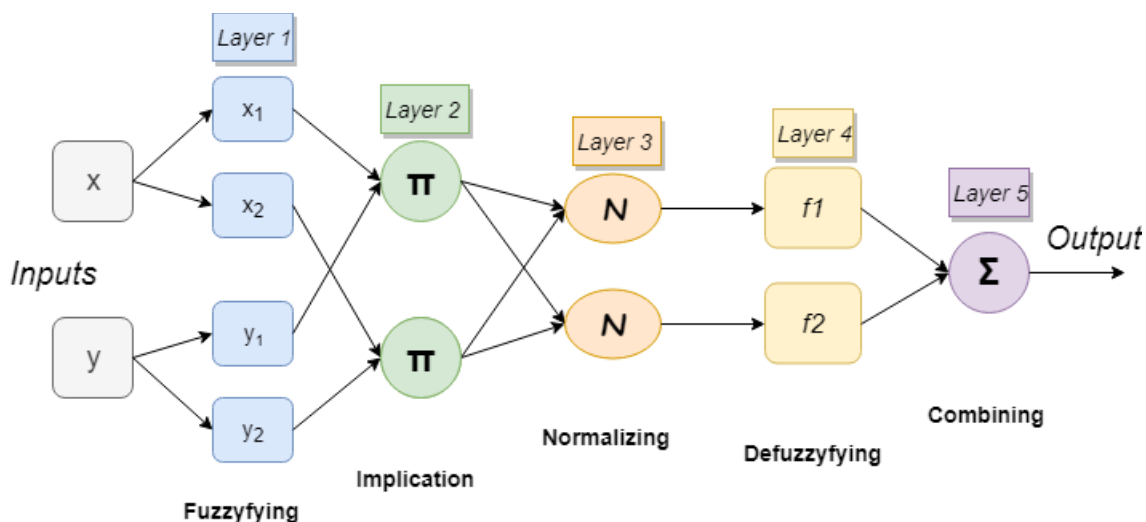
2. Indeks S&P 500

Indeks S&P 500 (Standard and Poor's 500) jest indeksem giełdowym, który bazuje na 500 amerykańskich spółkach akcyjnych o największej kapitalizacji. Korporacjami, które wchodzi w jego skład są m. in. firmy takie jak Microsoft Corporation, Apple Inc., Amazon.com Inc., Berkshire Hathaway Inc. Class B, Facebook Inc. Class A. Przedsiębiorstwa te należą do różnych gałęzi gospodarki: najwięcej – bo aż 17.73% składu w indeks mają firmy z sektora technologii, 16.71% to firmy świadczące usługi finansowe, następnie kolejno 12,97% i 12.18% dla sektora zdrowotnego i sektora dóbr konsumpcyjnych.



3. Procedura ANFIS

ANFIS jest to akronim od *Adaptive Neuro-Fuzzy Interference System*, oznaczający rodzaj sztucznej sieci neuronowej, bazującej na systemie wnioskowania rozmytego typu *Takagi-Sugeno*. Jako że procedura ta posiada właściwości zarówno sieci neuronowych, jak i logiki rozmytej, jest ona potencjalnie idealnym kandydatem do połączenia zalet obu tych koncepcji w jednym.



Ilustracja 1: Wewnętrzna architektura systemu ANFIS dla dwóch danych wejściowych

Wykorzystywany w procedurze typ systemu rozmytego *Takagi-Sugeno* posiada wiele podobieństw do domyślnie wykorzystywanego w takich systemach typu *Mamdani*. Jego przewagą jest między innymi efektywność obliczeniowa, gwarantowana liniowość wyjścia, umiejętność dobrej optymalizacji i wykorzystanie technik adaptacyjnych oraz szereg zastosowań w analizach matematycznych. Taki system rozmyty, wykorzystując funkcje przynależności oraz reguły *if-then*, może aproksymować funkcje nieliniowe.

Oprócz systemu wnioskowania rozmytego, za skuteczne rozpoznawanie i klasyfikację wzorców oraz predykcję szeregów czasowych odpowiada zawarta w procedurze sztuczna sieć neuronowa. Jednokierunkowe sieci neuronowe wykorzystywane są często jako samodzielna technika predykcyjna. Taka synteza dwóch gałęzi metod inteligencji obliczeniowej czyni ANFIS dobrym modelem do rozwiązania zadanego problemu predykcji indeksu giełdowego.

Jako wstępne parametry obraliśmy ilość funkcji przynależności dla wszystkich wejściowych zmiennych jako 2 oraz liczbę epok równą 10, co pozwalało na korzystanie z systemu w wydajny sposób w rozsądnym czasie.

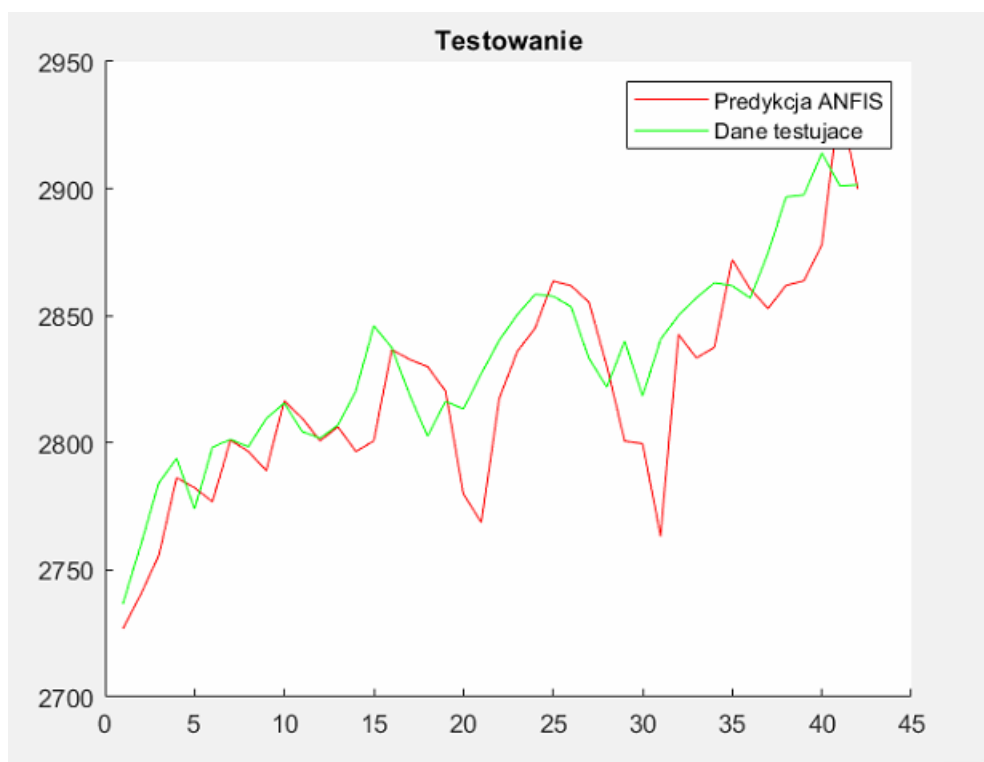
4. Predykcja indeksu zamknięcia

W zagadnieniu predykcji skupiliśmy się na wartościach indeksu zamknięcia, szacując że w przeważającej większości różnice pomiędzy cenami otwarcia, zamknięcia oraz pośrednimi są względnie małe, oraz wierząc że wybrany przez nas parametr wiernie odzwierciedla sytuację na rynku.

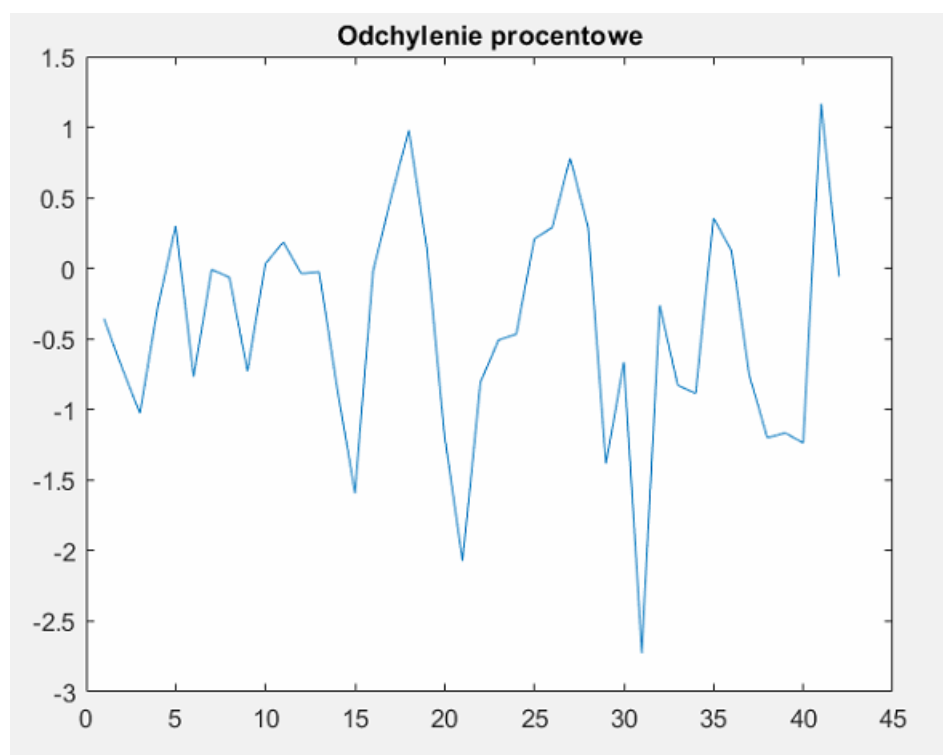
Aby osiągnąć jak najlepsze odniesienie do realnych notowań, oraz dla ewentualnych późniejszych zastosowań naszego systemu, przebadaliśmy go na przekrojowych danych obejmujących 600 dni, z różnymi tendencjami wzrostowo – spadkowymi, widocznymi na wykresach. Jako dni uczące posłużyły nam notowania pomiędzy 1.01 a 30.06.2017, a okres 1.07 – 31.08.2017 był okresem testującym nasz system.

Danymi uczącymi dla każdej dziennej prognozy było ustalone na początku n kolejnych dni poprzedzających. W pierwotnej wersji jako n założyliśmy wartość 5 dni.

Zaimplementowany przez nas program realizuje zadanie predykcji indeksu giełdowego osiągając średni błąd kwadratowy rzędu 120.9 na danych uczących oraz 632.9 na danych testujących (ilustracja 2). Średnia pomyłka ceny akcji dla badanego okresu wynosi 18.95\$. W zależności od przebiegu wartości notowań w testowanym okresie, zmienia się procentowa wartość odchylenia otrzymywanych wyników, również zobrazowana na wykresie (ilustracja 3). Odchylenie to waha się w granicach od 2.7% poniżej oczekiwanej wartości do 1.2% powyżej.



Ilustracja 2: Wykres danych testujących wraz z wynikiem predykcji



Ilustracja 3: Wykres odchylenia danych testujących w procentach

Do oszacowania efektywności przewidywań posłużyliśmy się także wskaźnikiem procentowym, opartym na dyskretnej analizie generowanych wyników, określającym względną liczbę dobrze przewidzianych spadków/wzrostów notowań cen akcji. Program w podstawowej wersji, na długim okresie testowym obejmującym znaczącą ilość zmiennych tendencji i schematów, osiągnął 67% skuteczność przewidywań.

Taki wynik zasugerował nam, by na świeczniku postawić dogłębną analizę najpierw właściwości naszego systemu, a następnie samych danych w kierunku zidentyfikowania najlepszej konfiguracji parametrów systemu, oraz najlepszego wyboru danych wykorzystanych do uczenia i tworzenia reguł logiki rozmytej.

Długość schematu – n

Zbadaliśmy, jakie wyniki otrzymamy modyfikując n - ilość dni poprzedzających.

liczba n	3	4	5	6
średni rozrzut danych uczących	8.05	9.81	11.2	12.44
średni rozrzut danych testujących	8.77	10.72	12.51	14.04
błąd średniokwadratowy danych uczących	243.5	201	120.9	79.9
błąd średniokwadratowy danych testujących	376.9	455.6	632.9	1195.1
średnia pomyłka ceny	\$15.90	\$17.20	\$18.90	\$26.63

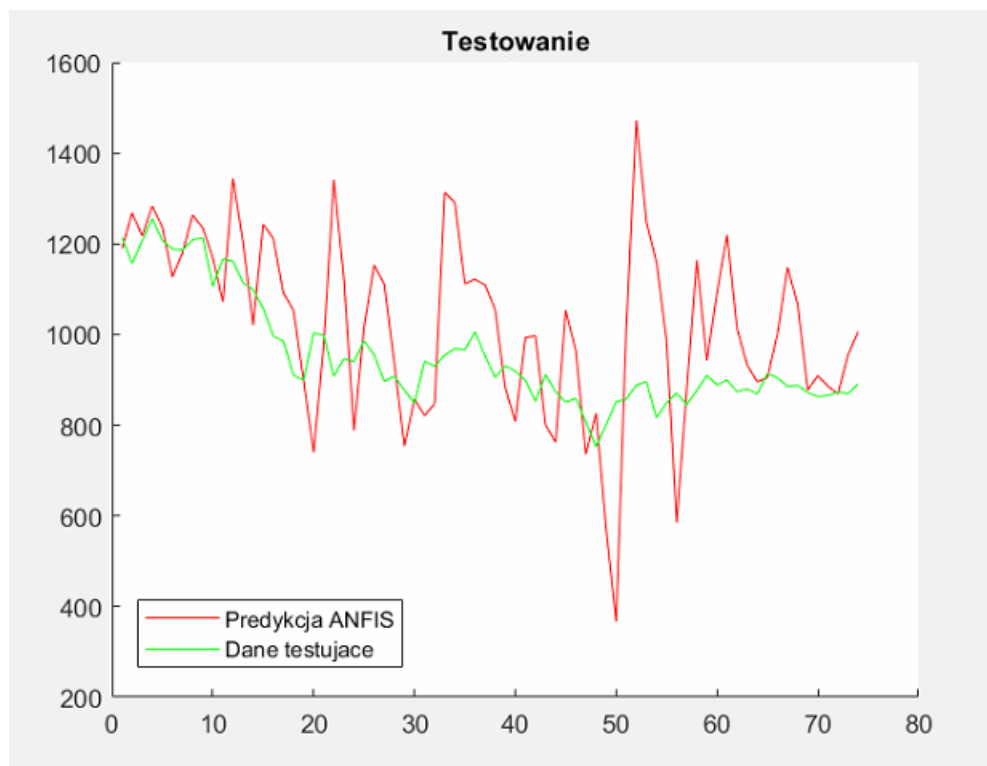
Dane doświadczalne wskazują jednoznacznie, że przy zwiększaniu n – a co za tym idzie ilości wejść systemu ANFIS – nie nastąpiła poprawa, stało się wręcz przeciwnie. Biorąc dodatkowo pod uwagę koszty czasowe z którymi związana jest ta modyfikacja, zwiększenie tego parametru staje się nieopłacalne.

Co bardzo ciekawe, błąd średniokwadratowy danych uczących nie jest intuicyjnie proporcjonalny do tegoż błędu dla danych testujących. Dla większej wartości n , pomimo zmniejszającego się stopniowo błędu uczenia, testowanie przebiega z coraz gorszą efektywnością.

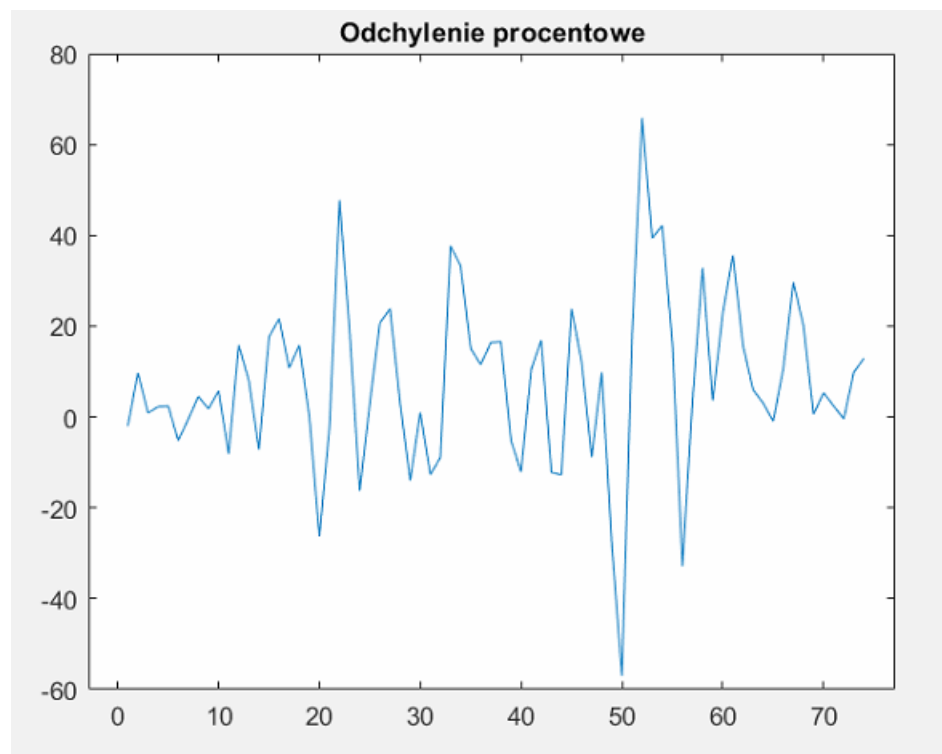
Przypadek statyczny i krytyczny

Przekrojowe dane obejmujące różne trendy rynkowe, w szczególności gdy brane są pod uwagę duże okresy czasowe, uśredniają spodziewaną skuteczność działania systemu, natomiast dla celów krótkoterminowej predykcji warto zbadać, czy gwałtowne i burzliwe zjawiska na rynku mogą stać się słabą stroną naszej techniki predykcyjnej.

Dobrym przykładem okresu, mogącym posłużyć za obraz tzw. krachu rynkowego jest rok 2008, w którym nastąpił szczyt kryzysu gospodarczego, mający odzwierciedlenie również w badanym przez nas indeksie S&P 500. Po nauczaniu ANFIS danymi z początkowych miesięcy roku, przetestowaliśmy jego działanie na okresie od połowy września do końca grudnia 2008.

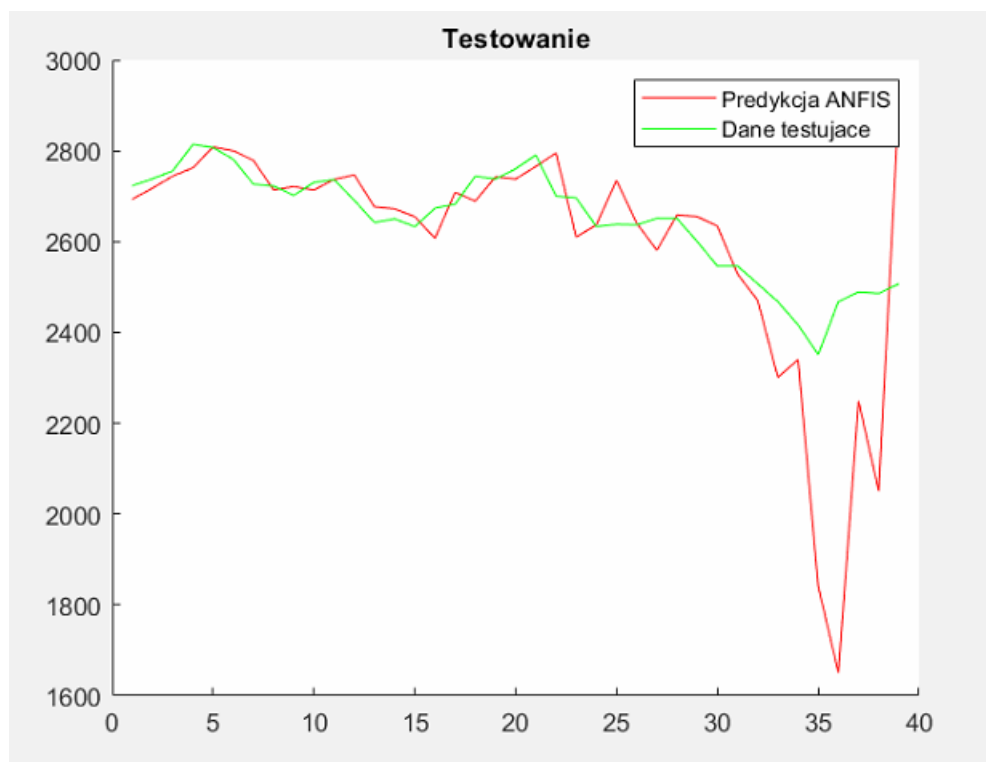


Ilustracja 4: Predykcja indeksu w okresie kryzysu gospodarczego w 2008



Ilustracja 5: Wykres odchylenia danych testujących w procentach


Jak mogliśmy przypuszczać, predykcja takiej sytuacji okazała się wyzwaniem, któremu nasza procedura predykcyjna nie zdołała sprostać. Odchylenie sięgające ponad 70 % wartości notowań, co odpowiada ponad 600\$ w faktycznych jednostkach cen akcji, nasuwa wniosek o bezużyteczności systemu w zderzeniu z gwałtownym spadkiem notowań. Wniosek ten sprawdza się także na podobnej sytuacji, tym razem z roku minionego, kiedy to również (oczywiście w znacząco mniejszej skali) nastąpiła gwałtowna zmiana na rynku.



Ilustracja 6: Wynik predykcji testowany na końcowym okresie roku 2018

Na wykresie dokładnie widać, jak w momencie nastąpienia dużych zmian na rynku znacząco spada skuteczność przewidywań, podczas gdy w okresie bardziej statycznym prognoza jest zadowalająca.

Wśród historycznych danych odnajdziemy także takie, w których zmiany następowały bardzo powoli oraz tendencyjnie, i występował stały statyczny, mało ruchliwy przebieg notowań. Przykładem takiego okresu był rok 2017, o utrzymującym się stałym trendzie wzrostowym przez cały badany okres. Dla takich właśnie danych nasza procedura znajduje najlepsze zastosowanie.



Ilustracja 7: Działanie systemu w konfrontacji z łagodnymi wahaniami notowań

Analiza danych

Dokładne przyjrzenie się dostępnym historycznym danym pozwoliło nam na opracowanie wstępnych założeń dotyczących natury rynku, które mogliśmy wykorzystać do dalszych rozważań na temat naszego systemu. Na przestrzeni ponad 19 ostatnich lat miało miejsce wiele obserwowalnych tendencji, i zarówno w skali makroskopowej, jak i mikroskopowej. Zauważyliśmy na przykład ogólny trend wzrostowy utrzymujący się w przybliżeniu stale w okresie ostatnich 10 lat. W skali miesięcy, w ostatnim czasie pojawiały się zarówno okresy silnie wzrostowe, spadkowe, jak i bardzo statyczne. Natomiast wzięcie pod lupę niewielkich okresów czasowych obejmujących kilka ostatnich dni pozwala na stwierdzenie, że w normalnych warunkach rzadko zdarzają się krótkoterminowe tendencje monotoniczne obejmujące więcej niż 4 dni. Nasuwa nam się spostrzeżenie, że jeśli w skali makro zachodzi tak silna zależność – mianowicie wyniki zależą od rozrzutu oraz monotoniczności danych, taka tendencja może wystąpić również w skali mikro.

Pierwszym więc z czynników, mogących wpływać na wysokość błędu wyników, jest rozrzut danych poprzedzających prognozowany dzień. Podzieliliśmy nasze dane testujące na takie o małym rozrzucie (mniejszym niż średni rozrzut n – elementowego wejścia systemu) oraz te o dużym rozrzucie (większym od średniej). Następnie zbadaliśmy wyniki procentowe przewidywań dla tych typów danych. Dokładna analiza danych na różnych badanych okresach testowych prezentuje się jak poniżej:

l.p.	1	2	3	4	5	ŚREDNIA
duży rozrzut danych	59.1	68.4	47.4	42.9	59.1	55.38
mały rozrzut danych	75	47.8	69.6	57.1	58.8	61.66

Kolejnym czynnikiem, który wydaje się interesujący w kontekście potencjalnego zwiększania skuteczności systemu jest monotoniczność danych. Aby uznać poprzedzające dane za monotoniczne, zadaliśmy warunek, by co najmniej 3 dni poprzedzające miały stałą tendencję wzrostową lub spadkową. Wyniki przedstawiają się następująco:

l.p.	1	2	3	4	5	ŚREDNIA
dane monotoniczne	65.2	56.52	60.9	47.8	40	54.084
dane niemonotoniczne	68.4	57.9	57.9	52.5	78.9	63.12

Wnioski nasuwające się z analizy badań skłaniają nas by pójść o krok naprzód, aby odnaleźć taką konfigurację danych rynkowych, by system jak najlepiej potrafił prognozować wyniki. Zauważając widoczną przewagę danych o małym rozrzucie oraz mniej monotonicznych, zastosowaliśmy podwójne kryteria klasyfikacji danych, wyniki których można zobaczyć poniżej:

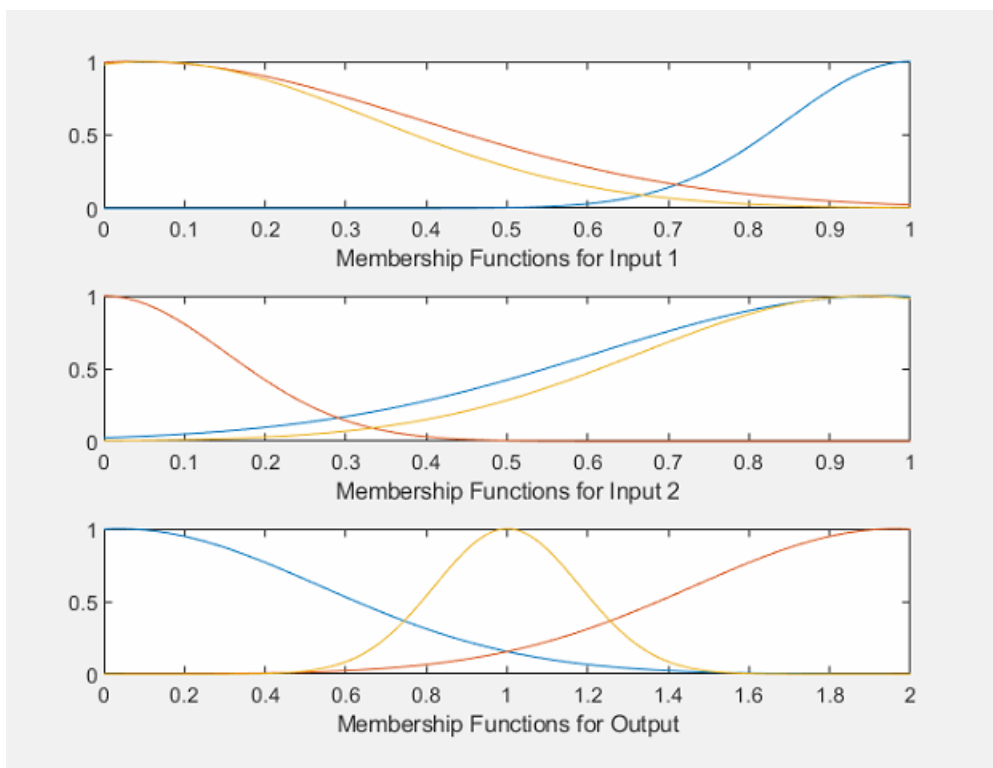
l.p.	1	2	3	4	5	ŚREDNIA
dane duże monotoniczne	44.8	60	64.3	50	50	53.82
dane małe niemonotoniczne	71.5	75	50	64.3	70	66.16

5. Algorytm decyzyjny

Bazując na wynikach naszych pomiarów, proponujemy prostą strukturę systemu wnioskowania rozmytego, która realizowałaby praktyczną część zagadnienia – mianowicie, na ile – w zależności od aktualnej sytuacji panującej na rynku w ciągu ostatnich dni – możemy ufać przewidywaniom naszego programu. System ten spełniałby funkcję pewnego rodzaju algorytmu decyzyjnego.


Do zbudowania tej struktury posłużyliśmy się wynikami prezentowanych wcześniej pomiarów dla zróżnicowanej liczby danych uczących i testujących oraz w różnych badanych okresach. Pomiarów te pozwalają nam na zgrubne oszacowanie, że najlepszych wyników możemy spodziewać się gdy ostatnie dane mają niewielki rozrzut oraz ostatnie 3 dni nie miały tendencji monotonicznej.

System posiada dwa wejścia, którymi są zero-jedynkowe wektory określające rozrzut danych (małe – duże) oraz ich monotoniczność zgodnie z wcześniejszymi warunkami. Wyjściem natomiast mieszcząca się w przedziale 0 – 2 informacja, na ile możemy ufać przewidywaniom procedury ANFIS w zależności od tego, jak wyglądał indeks zamknięcia S&P 500 w poprzednich kilku dniach.



Ilustracja 8: Funkcje przynależności dla wejścia i wyjścia systemu decyzyjnego

System testowaliśmy dla puli danych w innych - niż uczący – okresach. Otrzymaliśmy zgodność z wynikami procedury ANFIS na poziomie średnio 57%, co z uwagi na stosowanie bardzo dużych uproszczeń i silnych założeń wydaje się względnie dobrym wynikiem. System decyzyjny może być więc w pewnych sytuacjach stosowany do zwiększenia prawdopodobieństwa trafnych przewidywań. Po wstępnej obróbce danych z ostatnich dni możemy za jego pomocą ułatwić sobie decyzję o ewentualnej inwestycji.



Ilustracja 9: Wykres powierzchni decyzyjnej systemu wnioskowania rozmytego

6. Podsumowanie

Predykcja indeksu giełdowego jest procesem niezwykle trudnym i złożonym. Powszechnie jest stosowanie w tym celu analiz technicznych różnorodnych danych rynkowych, jednak metody te uznawane są przez niektórych za pseudonaukę, niepotwierdzoną doświadczalnymi badaniami. Wykorzystywane techniki niejednokrotnie są jednak względnie skutecznym sposobem wspomagania decyzji i opracowywania strategii inwestycyjnych.

Stworzony przez nas program posiada wszystkie aspekty efektywnych modeli predykcyjnych – zastosowana w nim procedura ANFIS jest syntezą kilku metod inteligencji obliczeniowej, z wszystkimi ich znanymi zaletami. Nasz system spełnia jednak podwójną rolę – oprócz samej predykcji realizuje także problem decyzyjny – mianowicie jak i kiedy można z największym prawdopodobieństwem powierzyć sztucznej inteligencji swoje poczynania giełdowe.